

MAE0524 - Análise Bayesiana de dados - primeiro semestre de 2019  
Professora: Márcia D'Elia Branco

LISTA 5

1) Um caso especial do modelo linear geral é o modelo de análise de variância usado para comparação de médias de  $K$  populações independentes normais com variâncias iguais.

a) Considere  $n_j$  o tamanho da  $j$ -ésima amostra, com  $j = 1, \dots, K$  e  $\mu_1, \dots, \mu_K$  as médias populacionais. Escreva o modelo de análise de variância na estrutura do modelo linear geral, especificando a matriz de planejamento  $X$  e relacionando as médias populacionais com o vetor de parâmetros  $\beta$ .

Usando os resultados apresentados em aula para o ML e considerando suposições adequadas, responda a questão a seguir:

b) Um conjunto de 19 porcos foi subdividido em 4 grupos, cada um dos quais foi alimentado durante certo período com diferentes tipos de ração. Ao fim desse período os porcos foram pesados e os valores são apresentados na tabela abaixo.

Tipo de Ração	Peso (kg)					
A	133.8	125.2	143.1	128.9	135.7	
B	151.2	149.0	162.7	145.8	153.5	
C	225.8	224.6	220.4	212.3		
D	193.4	185.3	182.8	188.5	198.6	

b.1) Compare as médias dos pesos dos grupos C e D.

b.2) Faça uma análise de variância bayesiana do conjunto total de dados.

2) Considere o modelo de regressão linear simples com erros  $t$ -Student independentes. Obtenha a distribuição *a posteriori* do vetor  $(\alpha, \beta)$  condicional a  $\sigma^2$  e  $W = (w_1, \dots, w_n)$ , em que  $W$  é o vetor das variáveis latentes usadas na construção hierárquica do modelo.

3) Deseja-se ajustar o modelo não linear  $\beta_0 x^{\beta_1}$ , relacionando o peso ( $y$ ) com o comprimento ( $x$ ) de determinada espécie de peixe. Para isso será utilizada uma linearização do modelo dada por:

$$\log(y) = \beta_0^* + \beta_1 \log(x) + \epsilon,$$

em que  $\beta_0^* = \log(\beta_0)$  e  $\epsilon \sim N(0, \sigma^2)$ .

Na tabela abaixo apresentamos o comprimento (em cm) e o peso (em kg) de 25 exemplares de um peixe capturados na costa sul do Brasil.

x	10.2	19.0	22.3	23.8	24.9	26.1	26.9	27.9	28.5	29.2	30.1	31.0	31.7
y	0.01	0.09	0.12	0.18	0.19	0.23	0.24	0.31	0.33	0.32	0.33	0.40	0.45
x	32.4	32.9	33.3	34.1	34.6	35.5	36.3	37.0	38.0	39.0	39.6	43.0	
y	0.49	0.67	0.48	0.54	0.63	0.59	0.65	0.50	0.81	0.87	0.71	0.91	

a) Construa os diagramas de dispersão de  $y$  versus  $x$  e de  $\log(y)$  versus  $\log(x)$ . Comente.

b) Considerando *a priori* de Jeffreys, especifique a distribuição *a posteriori* conjunta de  $(\beta_0^*, \beta_1)$ . Simule uma amostra de tamanho  $M = 1000$  desta distribuição.

c) Com base na amostra simulada em (b), obtenha uma amostra de  $(\beta_0, \beta_1)$ . Aproxime as distribuições *a posteriori* marginais via histograma dos dados simulados. Obtenha os intervalos de credibilidade 0.90 para  $\beta_0$  e  $\beta_1$ .

d) Considere que a razão  $\frac{\beta_1}{(10^5 \beta_0)}$  seja de interesse para estudos sobre biologia da espécie. Aproxime a distribuição *a posteriori* dessa quantidade via histograma, obtenha estimativas pontuais para ela, bem como, o intervalo de credibilidade 0.90.

4) Considere um experimento onde os indivíduos indicam o número de eventos estressantes ( $y_i$ ) aos quais foram submetidos em determinado mês ( $i$ ). Os dados são apresentados na tabela a seguir

Mês	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
$y$	15	11	14	17	5	11	10	4	8	10	7	9	11	3	6	1	1	4

Vamos considerar o modelo de regressão loglinear Poisson:

$$\log \lambda_i = \beta_0 + \beta_1 i$$

em que  $Y_i \mid \lambda_i \sim \text{Poisson}(\lambda_i)$ .

(a) Sob distribuição *a priori* uniforme (imprópria) para  $(\beta_0, \beta_1)$ . Escreva uma função no **R** para calcular o logaritmo da posteriori.

(b) Use o algoritmo de metropolis com proposta passeio aleatório para simular uma amostra de tamanho 1000 da distribuição *a posteriori* de  $\beta_1$ . Apresente os valores simulados usando o gráfico *box-plot*.

(c) Obtenha um intervalo de credibilidade 0.9 para  $\beta_1$ .

(d) Considerando o intervalo construído em (c), você diria que há evidências para rejeitar a hipótese  $H_0 : \beta_1 = 0$  ?

5) Num estudo para implantação de turbinas eólicas numa dada zona mediu-se a velocidade  $X$  do vento (em m/s) a uma dada altura ao longo de várias ocasiões, obtendo-se os dados  $x = (x_1, \dots, x_n)$ . O modelo utilizado para descrever  $X$  é o modelo Weibull, cuja f.d.p. é proporcional a

$$\delta \alpha x^{\alpha-1} \exp[-\delta x^\alpha] I_{(0,\infty)}(x), \quad \delta > 0, \alpha > 0.$$

Considere as seguintes distribuições *a priori*:  $\delta \sim \text{Gama}(a, b)$  e  $\alpha \sim \text{Log-normal}(c, d)$ , onde  $a, b, c, d > 0$ .

Obtenha as distribuições condicionais completas e indique como deveria ser implementado o algoritmo de Gibbs para obter uma amostra da distribuição *a posteriori*.

6) Seja  $Y | p \sim \text{Bin}(n, p)$  e  $\theta = \log\left(\frac{p}{1-p}\right)$ . Considere  $\theta$  com distribuição *a priori* Normal com média zero e desvio padrão 0.25. Para  $n = 5$  e  $y = 5$ , determine a probabilidade *a posteriori* de  $\theta > 0$  usando as duas aproximações indicadas a seguir. (Note que  $\theta > 0$  equivale a  $p > 0.5$ )

(a) Use a aproximação normal para a densidade *a posteriori*.

(b) Use o algoritmo de Metropolis-Hasting com proposta passeio aleatório. No algoritmo considere o desvio padrão da proposta igual a duas vezes o desvio padrão da aproximação normal obtida em (a).

**Entrega: 18/06/2019**